# BioPerl

Février 2016

Bérénice Batut

■ berenice.batut@udamail.fr





## Principe

- Collection de module Perl
- Objectif: Faciliter le developpement de scripts Perl pour des applications bioinformatiques
- Open-source via une organisation GitHub
- Soutenu par Open Bioinformatics Foundation

#### Histoire

- 1996 : Début
- 2002
  - Premier Open Bio Hackathon
  - BioPerl 1.0
  - Article

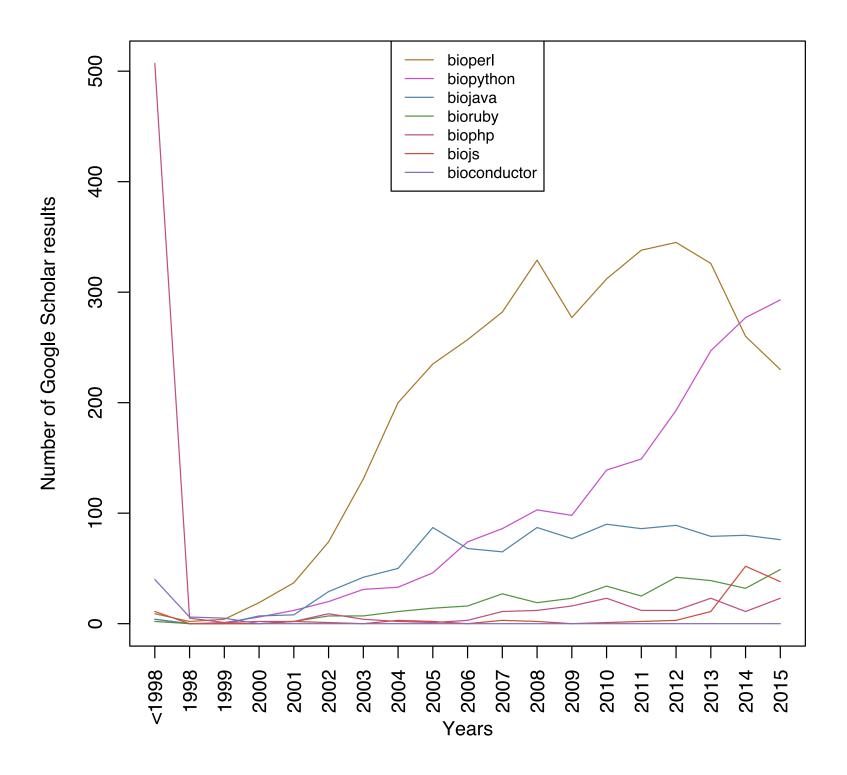
#### Actuellement

- GitHub
  - 31 contributeurs
- Dernière release: 1.6.924 en Juillet 2014
- Orienté-objet
- > 40 Modules Perl

## Comparaison avec les autres Bio Toolkits

### Bio Toolkits

	Release 1.0	Dernière release	Article majeur	Citations
BioPerl	2002	07/2014	2002	1 306
BioPython	2000	10/2015	2009	608
BioJava	2008	07/2015	2008	201
BioRuby	2006	07/2015	_	-
BioPHP	2003	?	_	-
BioJS	2013	09/2014	2013	44
Bioconductor	2001	10/2015		



### Installation

#### Installation sous Linux/Mac OS

```
$ (sudo) cpan -i CPAN
$ cpan
cpan[1]> d /BioPerl/
Reading '/Users/cidam/.cpan/Metadata'
   Database was generated on Thu, 14 Jan 2016 13:53:43 GMT
Distribution   B0ZO/Fry-Lib-BioPerl-0.15.tar.gz
Distribution   CDRAUG/Dist-Zilla-PluginBundle-BioPerl-0.20.tar.gz
Distribution   CJFIELDS/BioPerl-1.6.901.tar.gz
Distribution   CJFIELDS/BioPerl-1.6.923.tar.gz
Distribution   CJFIELDS/BioPerl-1.6.924.tar.gz
...
11 items found
cpan[2]> install CJFIELDS/BioPerl-1.6.924.tar.gz
```

#### Installation sous Windows



**DSSL** 

# Manipulation de séquences

## Représentation d'une séquence

#### 3 types d'objets pour une séquence

- Bio::PrimarySeq
  - Séquence + nom
  - Fichier fasta
- Bio::SeqFeatureI
  - Caractéristique sur une séquence (séquence, localisation et annotation)
  - Entrée simple d'une table de caractéristique EMBL/GenBank/DDBJ
- Bio::Seq
  - 1 séquence et une collection de caractéristiques
  - Entrée simple d'une table EMBL/GenBank/DDBJ

# Classe Bio::Seq

#### Classe Bio::Seq

```
NAME
     Bio::Seq - Sequence object, with features
...

DESCRIPTION
     A Seq object is a sequence with sequence features placed on it.
     The Seq object contains a PrimarySeq object for the actual sequence and also implements its interface.
...
```

#### Créer d'un objet Bio::Seq

```
use Bio::Seq;

my $seqobj = Bio::Seq->new(
    -seq => "ACTGTGTCC",
    -id => "Chlorella sorokiniana",
    -accession_number => "CAA41635"
);
```

#### Méthodes (1)

Méthodes renvoyant des chaines de caractères et acceptant parfois des chaine de caractères pour modifier des propriétés

```
$seqobj->seq();
                                # string of sequence
$seqobj->subseq(5,10);
                                # part of the sequence as a string
$seqobj->accession_number(); # when there, the accession number
                                # one of 'dna','rna',or 'protein'
$seqobj->alphabet();
                        # when there, the version
$seqobj->version()
$seqobj->keywords();
                                # when there, the Keywords line
$seqobj->length()
                                # length
$seqobj->desc();  # description
$seqobj->primary_id();  # a unique id for this sequence regardless
# of its display_id or accession number
$seqobj->display_id();
                                # the human readable id of the sequence
```

#### Méthodes (2)

Méthodes renvoyant des nouveaux objet Bio::Seq

```
$seqobj->trunc(5,10) # truncation from 5 to 10 as new object
$seqobj->revcom # reverse complements sequence
$seqobj->translate # translation of the sequence
```

#### Méthodes (3)

Méthode pour déterminer si une chaine de caractère peut être accepter par la méthode seq()

\$seqobj->validate\_seq(\$string)

#### Manipulation de séquences

#### Traduction

```
$translated_obj = $seqobj;
if( $seqobj->alphabet() == 'dna'){
    $translated_obj = $seqobj->translate();
}
print $translated_obj->seq(),"\n";
```

# Récupération de statistiques sur une séquence

#### Classe Bio::Tools::SeqStats

```
$ perldoc Bio::Tools::SeqStats
NAME
       Bio::Tools::SeqStats - Object holding statistics
       for one particular sequence
DESCRIPTION
   Bio::Tools::SeqStats is a lightweight object for the calculation of
   simple statistical and numerical properties of a sequence. By
   "lightweight" I mean that only "primary" sequences are handled by tl
   object. The calling script needs to create the appropriate primary
   sequence to be passed to SeqStats if statistics on a sequence featu
   are required. Similarly if a codon count is desired for a frame-
   shifted sequence and/or a negative strand sequence, the calling scr
   needs to create that sequence and pass it to the SeaStats object.
```

#### Méthodes

- count\_monomers
  - Comptage du nombre de chaque type de monomère
- get\_mol\_wt
  - Calcul du poids moléculaire
- count\_codons
  - Comptage du nombre de chaque type de codons
- hydropathicity
  - Calcul l'hydrophaticité moyenne de Kyte-Doolittle

# Manipulation de fichiers de séquences

#### Classe Bio::SeqIO

```
$ perldoc Bio::SeqIO
NAME
    Bio::SeqIO - Handler for SeqIO Formats
DESCRIPTION
   Bio::SeqIO is a handler module for the formats in the SeqIO set (eg
   Bio::SeqIO::fasta). It is the officially sanctioned way of getting
   the format objects, which most people should use.
   The Bio::SeqIO system can be thought of like biological file handle:
   They are attached to filehandles with smart formatting rules (eg,
   genbank format, or EMBL format, or binary trace file format) and call
   either read or write sequence objects (Bio::Seq objects, or more
   correctly, Bio::SegI implementing objects, of which Bio::Seg is one
```

#### Constructeur

- Paramètres possibles
  - -file
  - -string
  - -format: fasta, nexus, fastq, quality, excel, raw, tab, ...
  - -alphabet: dna, rna ou protein
- Création d'un objet Bio::SeqIO:ouverture d'un flux sur le fichier ou la chaine de caractères

#### Méthodes

- next\_seq
  - Lecture du prochain objet "séquence" dans le flux
  - Renvoi d'un objet Bio::Seq ou rien si aucune séquence disponible
- write\_seq
  - Ecriture d'un object Bio: Seq dans le flux
- format, alphabet, ...

#### Ecrire de séquences dans un fichier

#### Lecture des séquences d'un fichier

```
use Bio::SeqIO;

$seqio_obj = Bio::SeqIO->new(-file => "sequence.fasta",
        -format => "fasta" );

while ($seq_obj = $seqio_obj->next_seq){
    print $seq_obj->seq,"\n";
}
```

# Accès aux bases de données

# Récupération d'une séquence dans une base de données

#### Bases de données accessibles

Base de données	Module
GenBank	Bio::DB::GenBank
SwissProt	Bio::DB::SwissProt
GenPept	Bio::DB::GenPept
EMBL	Bio::DB::EMBL
SeqHound	Bio::DB::SeqHound
Entrez Gene	Bio::DB::EntrezGene
RefSeq	Bio::DB::RefSeq

#### Classe Bio::DB::GenBank

```
$ perldoc Bio::DB::GenBank

NAME
    Bio::DB::GenBank - Database object interface to GenBank

...

DESCRIPTION

Allows the dynamic retrieval of Bio::Seq sequence objects from the GenBank database at NCBI, via an Entrez query
...
```

#### Constructeur

```
use Bio::DB::GenBank;

$db_obj = Bio::DB::GenBank->new;
```

#### Méthodes

- get\_Seq\_by\_id(\$unique\_id)
- get\_Seq\_by\_acc(\$accession\_number)
- get\_Seq\_by\_version(\$versioned\_accession\_number)
- get\_Seq\_by\_gi(\$genbank\_gi\_number)

**A**Utiliser le bon identifiant pour la bonne méthode

# Récupération d'une séquence dans une base de données

```
use Bio::DB::GenBank;
use Bio::Seq;

$db_obj = Bio::DB::GenBank->new;

$seq_obj = $db_obj->get_Seq_by_id(2);
print $seq_obj->display_id(),"\n";
```

## Récupération de plusieurs séquences avec des requêtes plus complexes

# Bases de données et modules pour les requêtes

Base de données	Module
GenBank	Bio::DB::Query::GenBank
SwissProt	Bio::DB::Query::SwissProt
GenPept	Bio::DB::Query::GenPept
EMBL	Bio::DB::Query::EMBL
SeqHound	Bio::DB::Query::SeqHound
Entrez Gene	Bio::DB::Query::EntrezGene
RefSeq	Bio::DB::Query::RefSeq

### Classe Bio::DB::Query::GenBank

```
$ perldoc Bio::DB::Query::GenBank
NAME
    Bio::DB::Query::GenBank - Build a GenBank Entrez Query
DESCRIPTION
    This class encapsulates NCBI Entrez queries. It can be used to
    store a list of GI numbers, to translate an Entrez query expression
    into a list of GI numbers, or to count the number of terms that
    would be returned by a query. Once created, the query object can
    be passed to a Bio::DB::GenBank object in order to retrieve the
    entries corresponding to the query.
```

#### Constructeur

- Paramètres possibles
  - -db:protein, nucleotide, ...
  - -query
  - -mindate
  - -maxdate
  - -reldate
  - -datetype
  - -ids
  - -maxids
- Création d'un objet Bio::DB::Query::GenBank: ouverture d'un flux sur des objets Bio::Seq

#### Méthodes

- count
  - Renvoi du nombre de résultats de la requête
- ids
  - Renvoi/Modifie la liste des identifiants des résultats

### Récupération de plusieurs séquences

# Parser des rapports de recherche

#### Classe Bio::SearchIO

```
$ perldoc Bio::SearchIO
NAME
    Bio::SearchIO - Driver for parsing Sequence Database Searches (BLAS
    FASTA, ...)
DESCRIPTION
    This is a driver for instantiating a parser for report files from
   sequence database searches. This object serves as a wrapper for the
   format parsers in Bio::SearchIO::* - you should not need to ever use
   those format parsers directly. (For people used to the SeqIO system
   we are deliberately using the same pattern).
```

#### Constructeur

- Paramètres possibles
  - -file
  - format
  - -output\_format
  - -inclusion\_threshold
  - -signif
  - -check\_all\_hits
  - -min\_query\_len
  - best
- Création d'un objet Bio::Search avec un flux sur le fichier

### Formats

Name	Format
blast	BLAST (WUBLAST, NCBIBLAST, bl2seq)
fasta	FASTA -m9 and -m0
blasttable	BLAST -m9 or -m8 output (both NCBI and WUBLAST tabular)
megablast	MEGABLAST
blastxml	NCBI BLAST XML

6.4

#### Méthodes

- next\_result
- write\_result
- write\_report
- result\_count
- best\_hit\_only
- check\_all\_hits

# Représentation des données dans Bio::Search

- Bio::Search
  - Bio::Search::Result
    - Bio::Search::Hit
      - Bio::Search::HSP (high-scoring segment pair)

#### Méthodes de Bio::Search::Result

- algorithm
- query\_name
- query\_accession
- query\_length
- query\_description
- database\_name
- available\_statistics
- available\_parameters
- num\_hits
- hits

#### Méthodes de Bio::Search::Hit

- name
- length
- accession
- description
- algorithm
- raw\_score
- significance
- hsps
- num\_hsps
- locus
- accession\_number

### Méthodes de Bio::Search::HSP(1)

- algorithm
- evalue
- expect
- frac\_identical
- frac\_conserved
- gaps
- query\_string
- hit\_string
- length('total'/'hit'/'query')
- num\_conserved
- num\_identical

#### Méthodes de Bio::Search::HSP (1)

- rank
- seq\_inds('hit'/'query', 'identical'/
   'conserved'/ 'conserved-notidentical')
- score
- range('hit'/'query')
- percent\_identity
- strand('hit'/'query')
- start('hit'/'query')
- end('hit'/'query')
- matches('hit'/'query')
- get\_aln

# Parcours d'un fichier issu d'une requête Blast

### Références

- BioPerl GitHub Page
- Wiki BioPerl